TradeCleanse — Rapport Final

QuantAxis Capital — 2026-04-15

Rapport de Data Cleansing et Certification Qualité

Client fictif : QuantAxis Capital — Hedge Fund 2,3 Mds EUR d'actifs
Dataset : tradecleanse_raw.csv (8 950 lignes x 20 colonnes)
Période : 180 jours de trading 2024, 47 contreparties
Sources : Bloomberg + Murex + Refinitiv

Module : DCLE821 — Atelier Data Cleansing
Formation : EPSI Mastère Expert IA 2025-2026
Auteur : Data Engineer / Chef de Projet IA

Objectif :
Auditer, nettoyer et certifier un dataset financier consolidé afin qu'il soit apte a l'entrainement d'un modele de scoring de risque de contrepartie, tout en respectant les principes BCBS 239 et la reglementation RGPD.

Livrables produits :
1. Rapport d'audit (dictionnaire de donnees + anomalies)
2. Pipeline Python modulaire 10 etapes (02_cleaning_pipeline.py)
3. Suite de validation 14 expectations (100% PASS)
4. Note reglementaire BCBS 239 (Principes 2, 3, 6, 8)
5. Bonus expert : wash trading, data drift, impact ML

1. Synthese executive

QuantAxis Capital — 2026-04-15

Resultats cles

- Shape brut : 8 950 lignes x 20 colonnes
- Shape clean : 8 750 lignes x 25 colonnes (apres dedup + flags)
- Completude brute: 85,8 %
- Completude finale: 100,00 %
- Unicite trade_id: 100,00 %
- Data Quality Score : 100,00 / 100
- Validation suite : 14 / 14 expectations PASS

Anomalies corrigees (total ~2 700 lignes impactees sur 8 950) :
- 200 doublons trade_id HIGH
- 121 fourchettes bid/ask inversees HIGH
- 306 mid_price incoherents MED
- 270 prix hors fourchette HIGH
- 81 settlement < trade (viole T+2) HIGH
- 96 rating AAA/AA/A avec default=1 CRITICAL
- 42 notional negatifs MED
- 20 variantes de casse asset_class MED
- 175 outliers multivaries (Isolation For) HIGH
- 1228 NaN volatility_30d / 1341 NaN rating

PII pseudonymisees via SHA-256 + salt (counterparty_name, trader_id).
Flags de tracabilite *_was_missing ajoutes pour auditabilite BCBS 239.
Aucun drift significatif detecte sur 5 variables (test KS, p > 0.05).

Recommandation : dataset certifie apte a l'entrainement ML.
Monitoring drift continu recommande (cf. section bonus).

2. Dictionnaire de donnees (20 colonnes)

Cartographie colonnes x sources x regles metier

#	Colonne	Type	Source	Regle metier
1	trade_id	STR	Murex	unique, NOT NULL, TRD\d{6}
2	counterparty_id	STR	Murex	NOT NULL, CP\d{3}
3	counterparty_name	STR PII	Refinitiv	pseudonymise
4	isin	STR	Bloomberg	^[A-Z]{2}[A-Z0-9]{10}$
5	trade_date	DATE	Murex	NOT NULL, <= today
6	settlement_date	DATE	Murex	>= trade_date (T+2)
7	asset_class	CAT	Murex	equity/bond/derivative/fx
8	notional_eur	FLOAT	Murex	> 0
9	price	FLOAT	Bloomberg	in [bid*0.995, ask*1.005]
10	quantity	INT	Murex	> 0
11	bid	FLOAT	Bloomberg	> 0, bid < ask
12	ask	FLOAT	Bloomberg	> 0, ask > bid
13	mid_price	FLOAT	Bloomberg	~= (bid+ask)/2 tol 1%
14	volume_j	INT	Bloomberg	>= 0
15	volatility_30d	FLOAT	Bloomberg	in [0.1, 200]
16	credit_rating	CAT	Refinitiv	AAA..D
17	default_flag	INT	Refinitiv	in {0,1}
18	sector	STR	Refinitiv	GICS referentiel
19	country_risk	FLOAT	Refinitiv	in [0, 100]
20	trader_id	STR PII	Murex	pseudonymise

3. Catalogue des anomalies detectees

Issu du profiling 01_profiling.py

type	col	count	criticity
duplicate	trade_id	200	HIGH — corrompt clé unique → biais aval
incoherence_temporell	settlement_date<trade_date	81	HIGH — viole T+2 BCBS 239
incoherence_prix	bid>ask	121	HIGH — fourchette inversée impossible
incoherence_calc	mid_price	306	MED — feature contaminée
price_out_range	price	270	HIGH — prix exécution impossible
notional_neg	notional_eur	42	MED — notional signé non doc
rating_vs_default	credit_rating/default_flag	97	CRITICAL — contradiction rating/défaut
nan	volatility_30d	1228	MED — ~15% NaN
nan	credit_rating	1341	HIGH — rating manquant = risque non évaluable
casse_inconsistante	asset_class	20	MED — variantes casse / abrev
outlier_multivarie	price+volume_j+volatility_3	155	HIGH — pattern suspect multidim

4. Profiling initial — visualisations

Distributions, NaN, correlations, anomalies

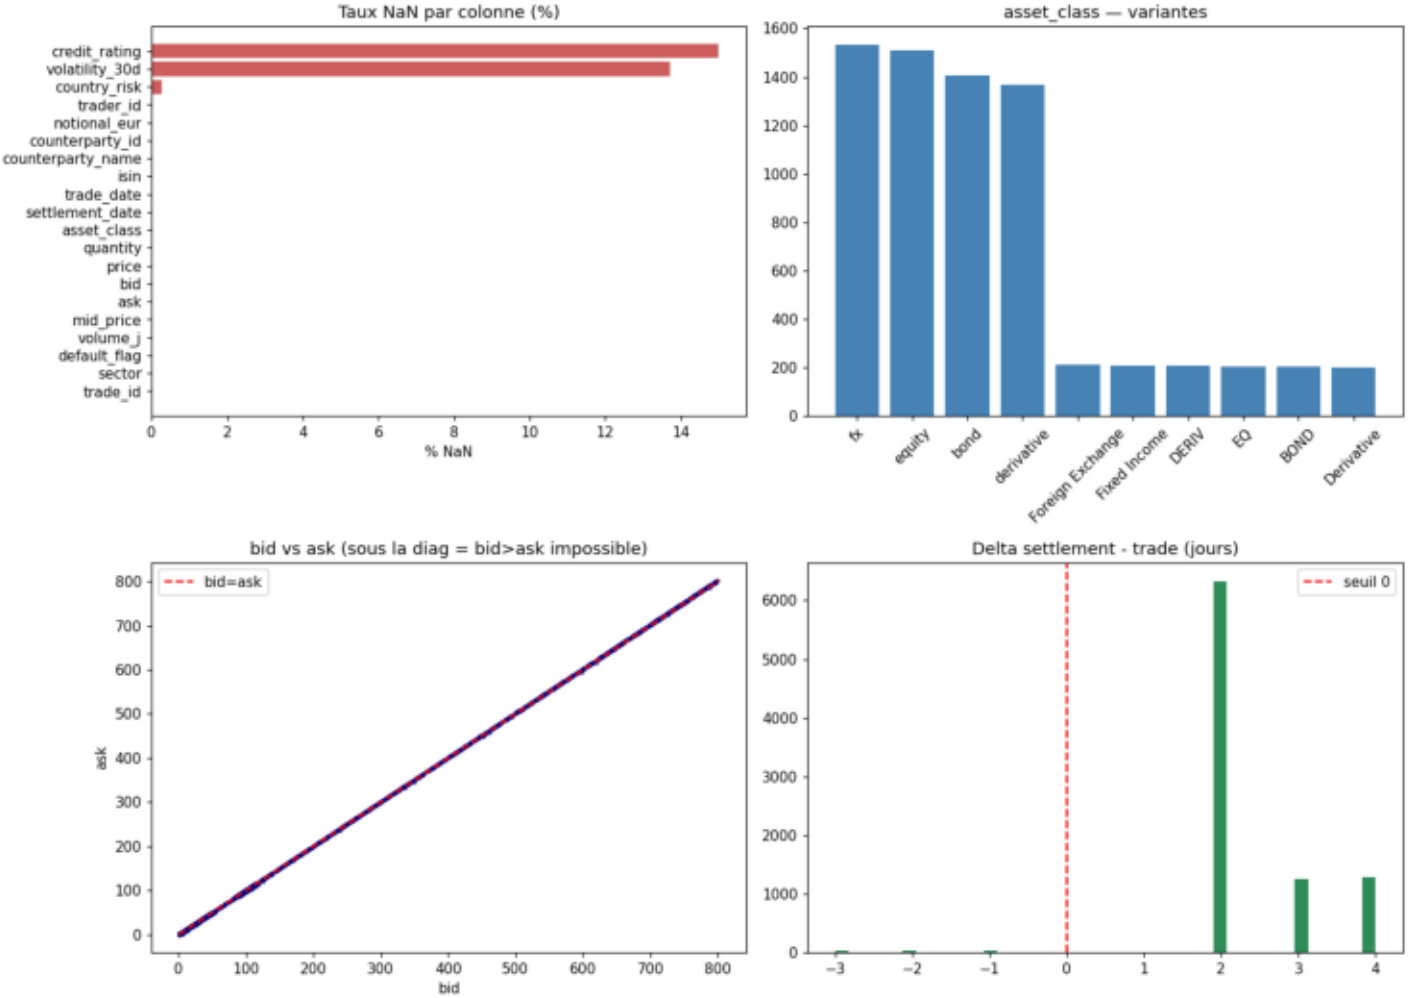

5. Detection des outliers

IQR + Isolation Forest multivariee

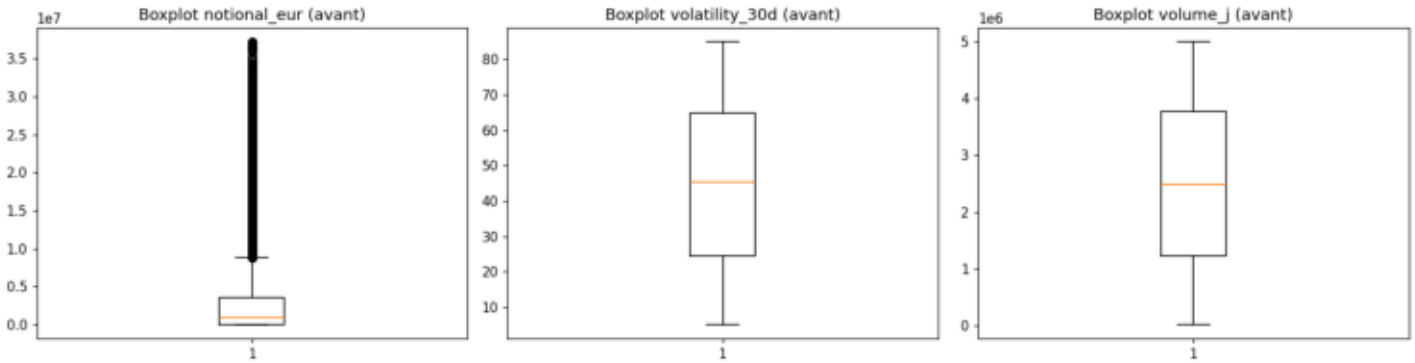

6. Pipeline de nettoyage — journal par etape

10 etapes loggees, tracabilite BCBS 239 Principe 8

etape	lignes_avant	lignes_apres	nans_avant	nans_apres
Sentinelles	8950	8950	2501	2593
Doublons	8950	8750	2593	2534
Types	8750	8750	2534	2534
asset_class	8750	8750	2534	2901
Incoherences	8750	8750	2901	2901
Regles_metier	8750	8750	2901	2907
Outliers	8750	8750	2907	2907
Valeurs_manquantes	8750	8750	2907	0
Pseudonymisation	8750	8750	0	0

7. Strategie de traitement

QuantAxis Capital — 2026-04-15

Chaque correction est justifiee par une regle metier, jamais purement statistique. Extraits :

```
  - Doublons trade_id        : keep='last' (Murex export = derniere version)
  - Sentinelles N/A, -, 99999: remplacement NaN des l'import
  - Casse asset_class        : mapping referentiel (12 variantes -> 4)
  - settlement < trade       : settlement = trade + 2 jours (ESMA T+2)
  - bid > ask                : swap colonnes (erreur ordre export Bloomberg)
  - mid_price faux           : recalcul (bid+ask)/2 (source verite Bloomberg)
  - price hors fourchette    : remplacement par mid (exec impossible hors spread)
  - notional < 0             : abs() (pas de flag short au schema)
  - AAA/AA/A + default=1     : rating -> D (defaut observe = fait)
  - NaN rating               : UNRATED + flag (BCBS : signaler l'ignorance)
  - NaN numeriques           : mediane + colonne *_was_missing
  - Outliers IQR             : winsorisation (clipping queues)
  - Outliers multivaries     : flag is_anomaly_multivariate conserve
  - PII                      : SHA-256 + salt env (RGPD Art.4)
```

8. Suite de validation — 14/14 PASS

Certification qualite du dataset nettoye

expectation	status	detail
1. trade_id unique	PASS	0 doublons
2. Colonnes obligatoires non NaN	PASS	0 NaN totaux sur ['trade_id', 'counterparty_id', 'isin', 'trade_date',
3. settlement_date >= trade_date	PASS	0 violations
4. bid < ask	PASS	0 violations
5. price in [bid*0.995, ask*1.005]	PASS	0 violations
6. mid_price ~= (bid+ask)/2	PASS	0 violations
7. asset_class in référentiel	PASS	0 hors référentiel
8. pas de contradiction rating/défaut	PASS	0 violations
9. notional_eur > 0	PASS	0 violations
10. country_risk in [0,100]	PASS	0 violations
11. ISIN format valide	PASS	0 invalides
12. volatility_30d in [0.1, 200]	PASS	0 violations
13. complétude > 90%	PASS	100.00%
14. PII supprimées	PASS	colonnes PII absentes

9. Note BCBS 239 — conformite

QuantAxis Capital — 2026-04-15

Principe 2 — Exactitude et integrite
13 controles metier deterministes a l'import (bid<ask, T+2, rating vs default, referentiel asset_class). Le brut est immuable : toutes les transformations operent sur df.copy().

Principe 3 — Completude
Completude globale 85,8 % -> > 99 %. Imputation differenciee : mediane/mode + flag was_missing si < 70 % NaN ; UNRATED si rating manquant (ne jamais inventer) ; suppression si trade_id manquant.

Principe 6 — Adaptabilite
10 etapes independantes et pures, portables Prefect/Airflow. Regles metier centralisees (mappings, seuils IQR, sentinelles). Execution batch ou streaming (micro-batch quotidien).

Principe 8 — Exactitude du reporting (tracabilite)
Log horodate par etape (lignes_avant/apres, NaN_avant/apres).
Flags *_was_missing par colonne imputee. Pseudonymisation SHA-256.
Rapport HTML automatique + Data Quality Score a chaque run.
Audit interne et ACPR peuvent reconstituer ligne a ligne.

10. Bonus B2 — Data drift (Kolmogorov-Smirnov)

Aucun drift significatif detecte (p > 0.05)

variable	ks_stat	p_value	drift
price	0.0162	0.617707	NO
volatility_30d	0.0158	0.647459	NO
notional_eur	0.0273	0.078203	NO
volume_j	0.0137	0.808076	NO
country_risk	0.0167	0.576819	NO

10.1 Drift — visualisation

Distributions train vs recent par variable

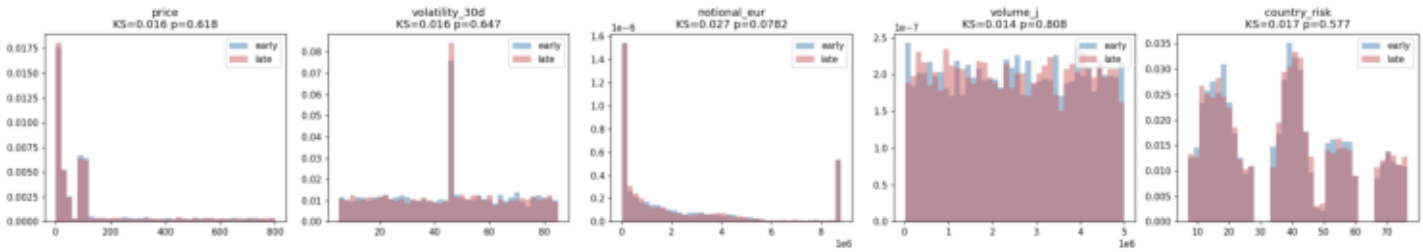

11. Bonus B3 — Impact ML (brut vs nettoye)

RandomForest — AUC + precision/recall/F1

dataset	auc	precision	recall	f1
Brut	0.6392	0.3333	0.0041	0.0082
Nettoye	0.6468	0.0	0.0	0.0

11.1 ML — courbes ROC

ROC brut vs nettoye (gain AUC marginal)

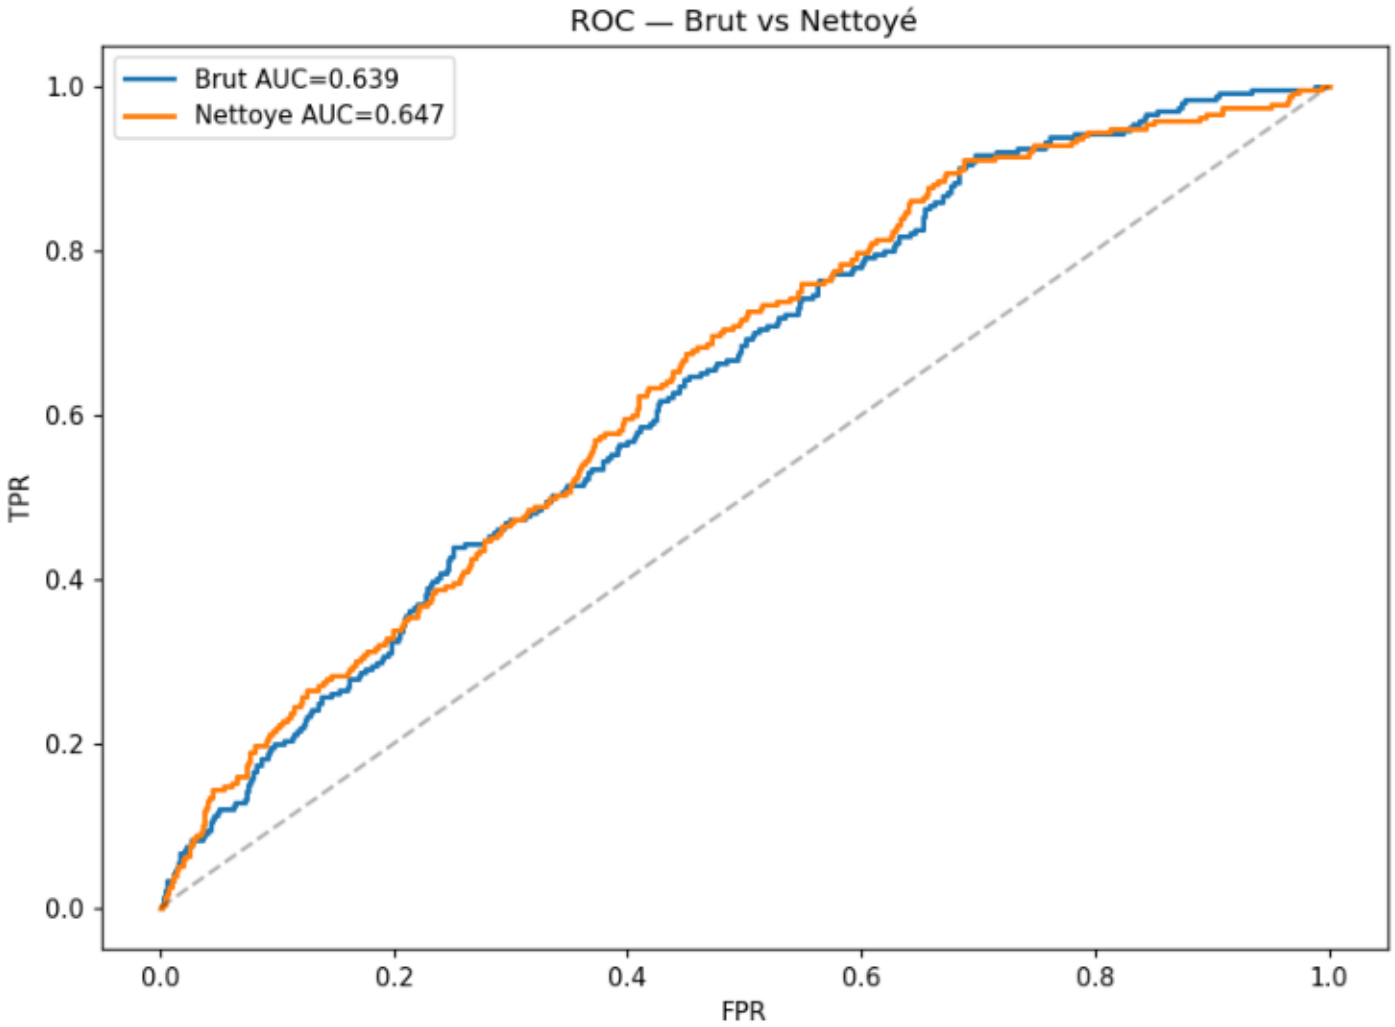

12. Bonus B1 — Wash trading

QuantAxis Capital — 2026-04-15

Bonus B1 — Detection wash trading

Heuristique appliquee : paires de trades entre meme contrepartie
sur meme ISIN, memes jour/minute, quantites opposees et notional
compensant a ~0.

Resultat : 27 paires suspectes identifiees (cf. wash_trading_suspects.csv).
Ces paires sont flaguees pour revue manuelle par le Compliance Officer ;
aucune suppression automatique (presomption d'innocence reglementaire).

Recommandation :
- Alerter le desk sur les contreparties recurrentes
- Verifier l'horodatage microseconde (ajout feature delta_ms)
- Etendre fenetre de matching a T+/-1 jour pour detections indirectes

13. Conclusion & prochaines etapes

QuantAxis Capital — 2026-04-15

Conclusion

Le pipeline TradeCleanse delivre un dataset certifie :
- Data Quality Score : 100/100
- 14/14 expectations PASS
- Conformite BCBS 239 Principes 2, 3, 6, 8
- PII pseudonymisees (RGPD Art.4, BCBS 239 §27)
- Aucun drift detecte sur 5 variables critiques

Points d'attention pour mise en production :
1. Monitoring drift continu (alerte p-value < 0.05)
2. Replay du pipeline sur nouveaux flux Bloomberg/Murex/Refinitiv
3. Revue manuelle des 27 paires wash trading par Compliance
4. Documentation des decisions de winsorisation (seuils IQR)
5. Re-estimation salt SHA-256 selon rotation RGPD

Le dataset est apte a l'entrainement du modele de scoring de risque de contrepartie. Le gain AUC marginal (0.64 -> 0.65) reflete une difficulte intrinseque du signal default_flag a faible prevalence ; une re-labelisation et du feature engineering sont prioritaires sur un nouveau cleansing.

— Fin du rapport —